

Descritor de Imagens com Deep Learning

Grupo: Natanael Neto, José Augusto, João Paulo,
Renan Florentino

PARTE 1

Problema, arquitetura e dados

Duas metades, só uma precisa de treino

Entender a imagem

CNN pré-treinada

congelada

4 milhões de parâmetros

Escrever a frase

Decoder GRU

treinado do zero

8 milhões de parâmetros

Como as peças se encaixam



A saída da CNN entra como estado inicial do GRU

DADOS

Flickr8k, traduzido para português

8.091

imagens

5

legendas cada

39.533

pares usados

59s

extrair as features

Limpar

minúsculas, acentos mantidos

Delimitar

tokens inicio e fim

Vetorizar

8.000 palavras, padding 22


```
inicio  uma criança em um vestido rosa está subindo escadas  fim
```

Split por imagem: 7.282 treino / 809 validação

PARTE 2

Como o modelo aprende

Escrever é prever a próxima palavra



cada palavra gerada volta como entrada para prever a seguinte

Autocompletar

mas condicionado pela imagem

8.000 opções


uma nota para cada palavra

O token fim

encerra a frase

Como ele escolhe cada palavra

um homem de camisa azul está ____



exemplo ilustrativo

greedy

pega a maior nota

temperatura

sorteia entre elas

O GRU guarda uma memória da frase

estado inicial

a imagem

>

+ "inicio"

estado 1

>

+ "um"

estado 2

>

+ "homem"

estado 3

o estado nunca é zerado

Porta de atualização

quanto da memória continua

Porta de reset

quanto pode ser esquecido

No treino, o alvo é a entrada deslocada

Entrada início uma criança em um vestido rosa

Alvo uma criança em um vestido rosa está

deslocado um passo

Sem teacher forcing

o erro contamina o resto da frase

Com teacher forcing

a entrada seguinte é sempre a palavra certa

PARTE 3

As camadas e o treino

O que o modelo recebe

x_feat

35589 x 1280

o vetor da imagem

x_texto

35589 x 21

a entrada

y

35589 x 21

o alvo, deslocado

21 e não 22: uma posição some porque entrada e alvo são a mesma frase deslocada

O MODELO

Da ideia para o código

Dropout (0.3)

regulariza o vetor da imagem

Dense (512, tanh)

projeta 1280 para o estado do GRU

Embedding (8000, 256)

palavra vira vetor

GRU (512)

imagem como estado inicial


Dense (8000)

uma nota para cada palavra

mask_zero ignora o padding · saída em logits, softmax fica na loss

TREINO

Convergiu em 18 épocas, 5,4 minutos



2,64

melhor val_loss

época 14 de 18

EarlyStopping

parou e restaurou os melhores pesos

ReduceLROnPlateau · 2 quedas

Resultados e Avaliação

GERAÇÃO

O modelo se alimenta da própria saída



Legenda de Referência

um jogador de rugby bloqueia enquanto segura a bola

Greedy

um homem de camisa azul está jogando um jogo de futebol

Temperatura 0.7

um homem está jogando um jogo de futebol

Acertou a cena esportiva, mas errou o esporte.

GERAÇÃO

O modelo se alimenta da própria saída



Legenda de Referência

Um menino de azul nas árvores

Greedy


Uma criança em um casaco de lã e jaqueta azul está correndo através de uma área arborizada

Temperatura 0.7

Um menino em uma jaqueta azul correndo nas árvores com galhos

Acertou o cenário, o personagem e as vestimentas

BLEU: comparação de n-gramas



A ressalva

Não entende sinônimos: cão e cachorro contam como erro

LIMITAÇÃO E PRÓXIMOS PASSOS

**Um vetor único representa a
imagem inteira**

Atenção

Fazer o modelo prestar atenção em
regiões específicas da imagem

Obrigado!